MongoDB Compas - Python

Base de datos | CUGDL





Alumno: Christian Edén Ureña Vázquez | Profesor: Marco Antonio Cisneros Guevara

1. Almacenamiento NoSQL: ¿Por qué el archivo CSV aplanado original es ineficiente y cómo optimiza MongoDB la estructura mediante documentos JSON/BSON?

- **Ineficiencia del CSV aplanado:** El archivo CSV original poseía más de 200 columnas repetitivas (intents[i].tag, intents[i].patterns, etc.) para intentar representar arreglos dentro de una estructura tabular bidimensional. Esto generaba una enorme cantidad de celdas vacías (NULL / NaN), redundancia masiva de datos, desperdicio de almacenamiento y gran dificultad para realizar búsquedas o filtrados en listas de longitud variable.
- **Optimización en MongoDB (JSON/BSON):** MongoDB utiliza el formato jerárquico BSON (Binary JSON), permitiendo almacenar las listas de patrones y respuestas como arreglos o vectores nativos dentro de un único documento por intención. Esto elimina las columnas nulas, reduce drásticamente el espacio en disco, aporta un esquema flexible que se adapta a documentos con distinto número de patrones y agiliza el rendimiento en la lectura e indexación de datos semiestructurados.

2. Sintaxis de Consultas: ¿Qué diferencia existe al ejecutar {"num_patrones": {"$gt": 5}} frente a {"num_patrones": {"$gte": 5}} en Compass?

- **{"num_patrones": {"$gt": 5}} ($gt = Greater Than):** Filtra y retorna únicamente los documentos donde la cantidad de patrones sea **estrictamente mayor que 5** (es decir, categorías con 6, 7, 8 o más patrones).
- **{"num_patrones": {"$gte": 5}} ($gte = Greater Than or Equal):** Filtra y retorna los documentos donde la cantidad de patrones sea **mayor o igual que 5** (incluye los documentos que tienen exactamente 5 patrones, además de los mayores a 5).

3. Conectores: ¿Cuál es la función del paquete pymongo en el flujo de trabajo entre la base de datos y Jupyter Notebook?

La función del paquete **pymongo** es actuar como el **driver o conector de comunicación oficial** entre la base de datos NoSQL (MongoDB) y el entorno de desarrollo en Python. Permite establecer la conexión con el servidor (MongoClient), ejecutar consultas de selección y filtrado (collection.find()), extraer los documentos BSON y convertirlos a colecciones nativas de Python (diccionarios y listas). Esto facilita transformar la información directamente en un DataFrame de Pandas para realizar el análisis exploratorio, calcular métricas y entrenar modelos predictivos con Scikit-Learn.

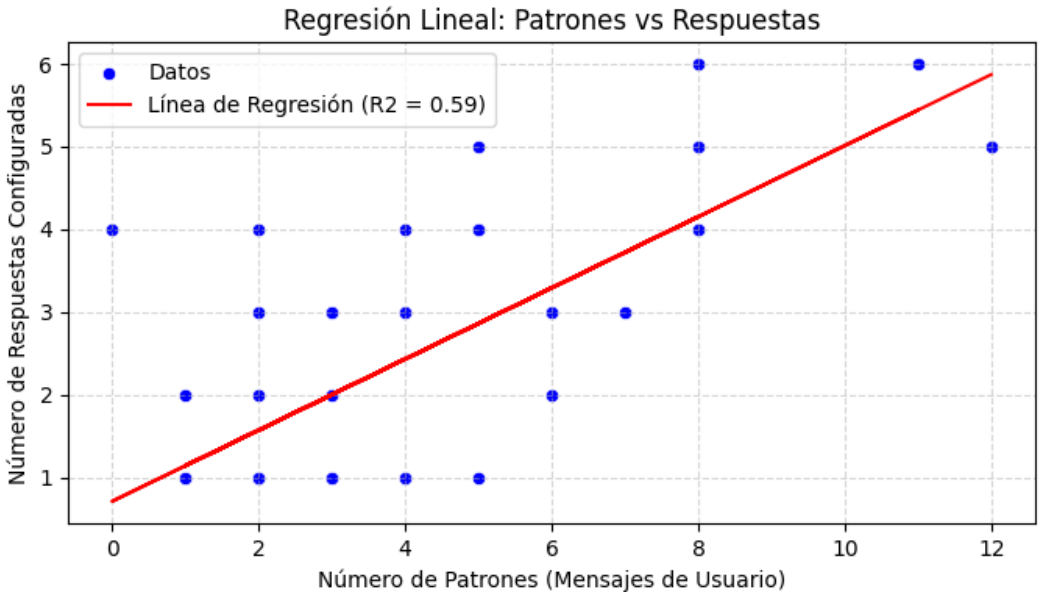
4. Estadística Aplicada: En la ecuación $Y = mX + b$, ¿qué representa geométricamente el valor del coeficiente m en el contexto del chatbot?

- **Representación geométrica:** El valor del coeficiente m representa la **pendiente** de la recta de regresión lineal en el plano cartesiano.
- **Contexto del chatbot (con $m = 0.430$):** Indica la **tasa de cambio promedio** del número de respuestas (Y) con respecto al número de patrones de entrada (X). En este dataset, un valor de $m = 0.430$ significa que por cada patrón (mensaje de usuario) adicional que se configure en una categoría, se añaden en promedio **0.430 respuestas** predeterminadas al chatbot.

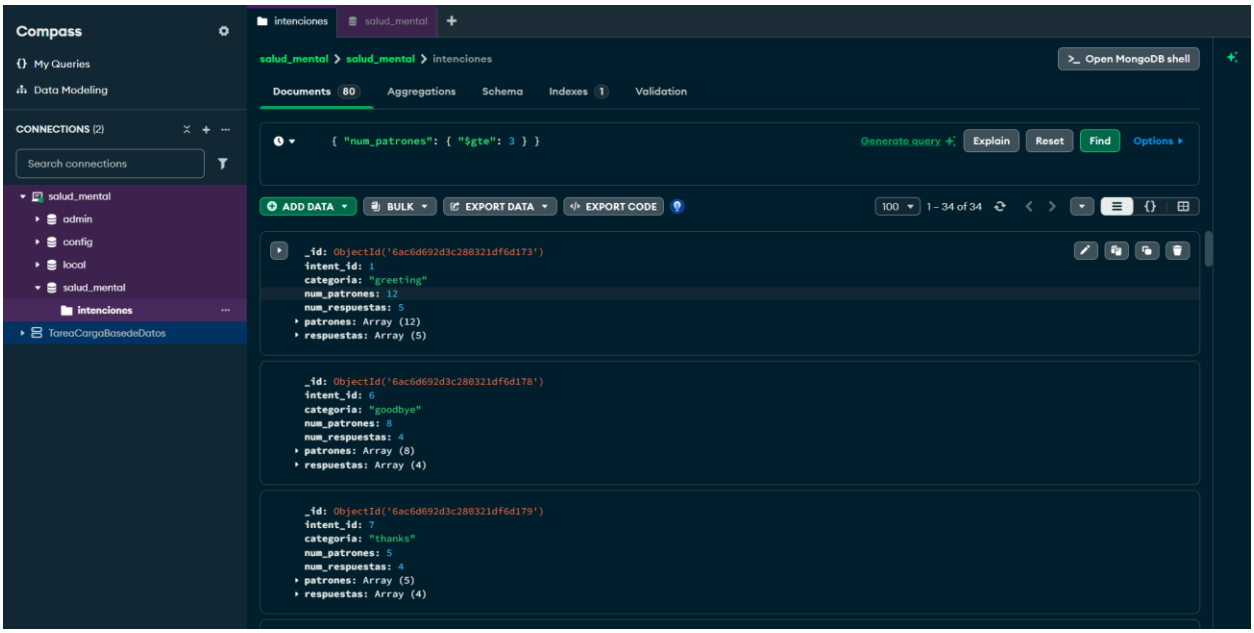
5. Interpretación del Modelo: Si obtienes un Coeficiente de Determinación (R^2) cercano a 0, ¿qué conclusión se obtiene sobre la relación entre patrones y respuestas?

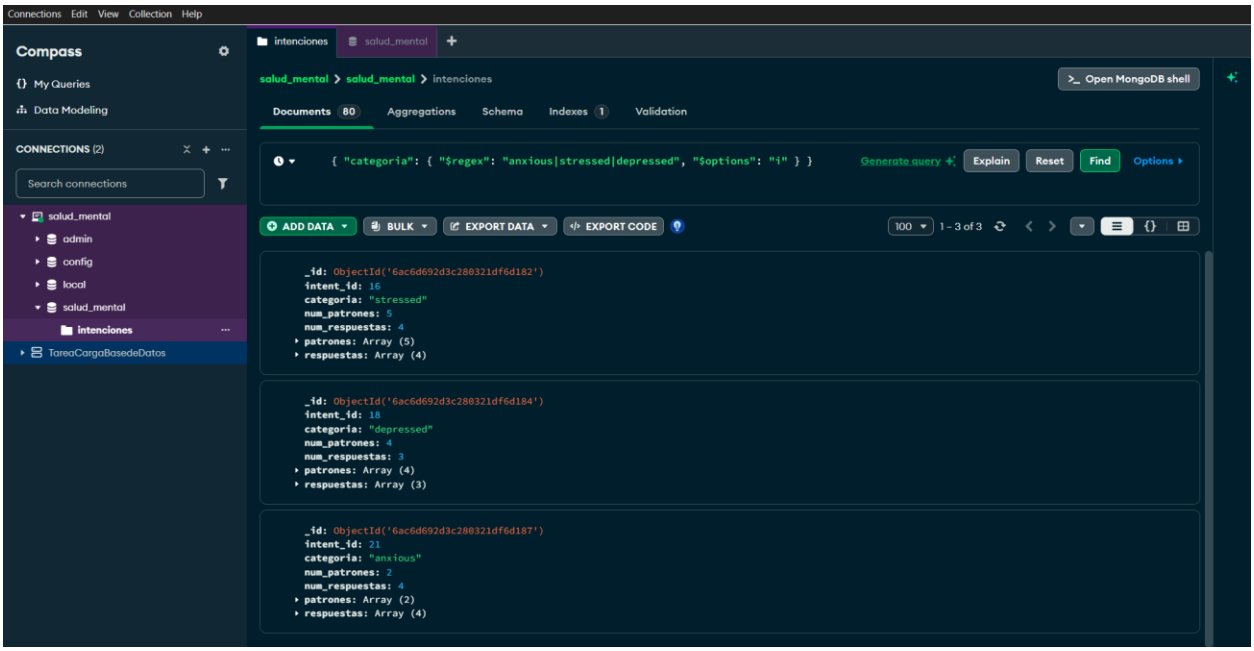
- **Conclusión teórica ($R^2 \approx 0$):** Si el Coeficiente de Determinación fuera cercano a 0, indicaría que la variable independiente (X: número de patrones) no explica la variabilidad de la variable dependiente (Y: número de respuestas). Esto llevaría a la conclusión de que **no existe una relación lineal** entre cuántas preguntas hace el usuario y cuántas respuestas están configuradas en el chatbot.
- **Análisis con tus resultados reales ($R^2 = 0.593$ y $MSE = 3.5875$):**
    - Con un $R^2 = 0.593$, tu modelo demuestra que aproximadamente el **59.3% de la variabilidad** en la cantidad de respuestas de una intención se explica linealmente a través del número de patrones configurados. Esto evidencia una relación lineal **moderadamente fuerte**.
    - El **Error Cuadrático Medio ($MSE = 3.5875$)** refleja la varianza del error del modelo, mostrando que las desviaciones al cuadrado entre el número de respuestas reales y las predichas por la recta tienen un promedio de 3.5875 unidades.

Gráfico Regresión Lineal



Capturas de pantalla MongoCompass





Reto Análisis

Aquí tienes las **respuestas redactadas con los datos reales obtenidos en tu ejecución** ($Y = -115.414X + 286.129$, $R^2 = 0.0074$), formateadas para adjuntar directamente a tu reporte:

1. Feature Extraction: ¿Cómo transforma la librería TextBlob una cadena de texto no estructurada en un valor numérico de polaridad?

La librería **TextBlob** procesa las cadenas de texto no estructurado (las concatenaciones de los patrones de usuario) mediante un análisis léxico preentrenado:

1. **Tokenización:** Divide el texto en tokens (palabras individuales) ignorando signos de puntuación.
2. **Diccionario de Sentimiento:** Analiza las palabras clave buscando coincidencias en un diccionario donde cada término tiene asignado un valor predeterminado de polaridad.
3. **Manejo de Modificadores y Negaciones:** Detecta adverbios intensificadores (ej. *"very"*) y negaciones (ej. *"not"*), ajustando o invirtiendo el valor del adjetivo/sustantivo contiguo.

4. **Agregación Contínua:** Calcula el promedio ponderado de la polaridad de las palabras presentes, retornando un valor numérico continuo entre -1.0 **(máxima carga emocional negativa / estrés)** y $+1.0$ **(polaridad positiva / neutra)**.

2. Interpretación de la Pendiente ($m = -115.414$): Si la pendiente m resulta ser negativa en tu modelo, ¿qué interpretación técnica tiene sobre el comportamiento del chatbot frente a mensajes de alta carga emocional negativa?

Con el valor obtenido de $m = -115.414$, la pendiente es negativa, lo que indica una **relación inversamente proporcional**:

- **Interpretación Técnica:** Conforme la polaridad del mensaje del usuario se vuelve más negativa (se aproxima a -1.0), la longitud promedio de la respuesta generada por el bot **aumenta a razón de aproximadamente** 115.4 **caracteres** por cada unidad de polaridad negativa.
- **Comportamiento del Chatbot:** Esto implica que el bot está diseñado para responder con mensajes más largos, detallados y reflexivos ante textos con alta carga emocional negativa (ansiedad, depresión, tristeza), buscando brindar orientación o soporte amplio; mientras que ante entradas neutras o positivas (polaridad alta) ofrece interacciones más breves y directas.

3. Evaluación de Ajuste ($R^2 = 0.0074$): ¿El sentimiento del usuario es un buen predictor de la longitud de la respuesta del bot? Justifica tu respuesta analizando el coeficiente R^2 obtenido.

- **Respuesta: No**, el sentimiento del usuario **no es un buen predictor** de la extensión de la respuesta del bot.
- **Justificación analítica:** El Coeficiente de Determinación obtenido fue de $R^2 = 0.0074$. Esto significa que la polaridad del mensaje del usuario explica únicamente el **0.74% de la variabilidad** en la longitud de las respuestas configuradas en el chatbot.
- El **99.26% restante** de la variación se debe a otros factores (como la categoría de la intención, reglas fijas de diseño de la interfaz o intenciones aleatorias sin relación lineal). Por lo tanto, no existe un ajuste predictivo válido ni una dependencia lineal estadísticamente relevante entre ambas variables en este modelo.